

Informe Proyecto 2

Predicción de cancelación de reservas en hoteles

Castellanos, I. (22128); Rodríguez, R. (18907)

Departamento de Matemática Aplicada, Facultad de Ciencias y Humanidades, Universidad del Valle de Guatemala; Instructor: Alan Reyes

Resumen

El informe analiza la predicción de cancelaciones de reservas hoteleras mediante técnicas de aprendizaje automático. Se trabajó con una base de datos de Kaggle compuesta por 25,811 registros y 16 variables. Después de realizar un análisis exploratorio, codificación de variables categóricas y separación de datos en entrenamiento y prueba, se entrenaron modelos Random Forest y XGBoost usando GridSearch y validación cruzada. Los resultados muestran que ambos modelos tuvieron una capacidad regular para clasificar cancelaciones, con métricas entre el 70–80% de recall. Random Forest presentó un desempeño ligeramente mejor en el conjunto de prueba, aunque con mayor sobreajuste. XGBoost con PolynomialFeatures mostró una mejora leve, pero no suficiente. Se concluye que las variables disponibles tienen capacidad limitada de separación y se recomienda aplicar selección de variables y ajuste de costos por etiqueta.

Palabras clave: cancelación de reservas, interacción de variables, Random Forest, XGBoost, sobreajuste, EDA.

Introducción

Las cancelaciones de reservaciones hoteleras son un problema relevante para la gestión de hoteles, ya que generan incertidumbre en la ocupación, los ingresos y la planificación operativa. El análisis de datos de reservas permite identificar patrones asociados con la cancelación, considerando variables como el tipo de hotel, el tiempo de anticipación de la reserva, la duración de la estancia, entre otros. Estudiar este tipo de información resulta útil para anticipar comportamientos de cancelación y apoyar la toma de decisiones mediante modelos predictivos (António. Almeida y Nunes, 2019).

El siguiente trabajo se realizó con el fin de determinar las principales variables que permiten predecir la cancelación de una reserva mediante EDA e importancia de características de dos algoritmos de Machine Learning.

Metodología

Se extrajo una base de datos de Kaggle en un Excel llamada HotelData.xlsx, en el que se recopila información acerca de reservaciones en un hotel de Estados Unidos.

Se realizó una exploración inicial de los datos mediante Python. En ésta se

determinaron la cantidad de datos del conjunto (25,811), el número de reservas que fueron canceladas (7,296) y el número de variables (16), así como los tipos de variables, las cuales 14 eran numéricas y 2 categóricas. Además, se identificó la variable objetivo (booking_status).

Se aplicó OneHotEncoder al conjunto de datos con el fin de tener solo variables numéricas, ya que los modelos utilizados solo pueden trabajar con este tipo de variables. No obstante, no se aplicó ningún escalamiento, ya que los modelos utilizados no son sensibles a escalas.

Se visualizaron los histogramas de cada variable con el fin de determinar las distribuciones y posibles sesgos de cada una. También se visualizó la relación entre cada variable respecto a la variable, con el fin de determinar que variables eran más prometedoras para realizar la separación de las etiquetas.

Se realizó la separación entre variables predictoras y la variable objetivo. Luego, se realizó la separación entre el conjunto de entrenamiento y el de prueba, se consideró la distribución de las etiquetas con el fin de no tener conjuntos de datos desbalanceados.

Se definió la rejilla de hiperparámetros sobre la cual se entrenaron los modelos, luego se definió un GridSearch, haciendo uso de validación cruzada, para mayor certeza estadística, teniendo la métrica recall como criterio de mejor modelo.

Se entrenaron modelos de Random Forest y XGBoost usando sus respectivas rejillas de hiperparámetros. El mejor modelo de

cada algoritmo fue usado en el conjunto de prueba y se analizaron sus resultados mediante una matriz de confusión y el reporte de clasificación.

Se determinó la importancia que cada modelo le asignó a cada una de las variables.

Se evaluó el sobreajuste de cada modelo, mediante la predicción en el conjunto de entrenamiento, haciendo uso del reporte de clasificación para compararlo con el reporte de clasificación del conjunto de prueba.

Por último, se evaluó una opción de modelo XGBoost, con el mismo procedimiento que el anterior, pero agregando interacción entre las distintas variables, hasta grado 2, con el fin de visualizar si se podía disminuir el sobreajuste y mejorar las predicciones.

Resultados

Cuadro 1. Tabla de métricas del conjunto de entrenamiento del modelo de XGBoost.

Etiquetas	Precision	Recall	F1	Support
0	0.96	0.98	0.97	14833
1	0.96	0.89	0.92	5815

Cuadro 2. Tabla de métricas del conjunto de prueba del modelo de XGBoost.

Etiquetas	Precision	Recall	F1	Support
0	0.88	0.91	0.90	3709
1	0.75	0.68	0.71	1454

Figura 1. Matriz de confusión del conjunto de prueba de XGBoost.





Figura 2. Gráfico de las variables más importantes del modelo de XGBoost.



Cuadro 3. Tabla de métricas del conjunto de entrenamiento del modelo de Random Forest.

Etiquetas	Precision	Recall	F1	Support
0	1	1	1	14833
1	0.99	0.99	0.99	5815

Cuadro 4. Tabla de métricas del conjunto de prueba del modelo de Random Forest.

Etiquetas	Precision	Recall	F1	Support
0	0.88	0.92	0.90	3709
1	0.77	0.66	0.71	1454

Figura 3. Matriz de confusión del conjunto de entrenamiento del modelo de Random Forest.





Figura 4. Gráfico de las variables más importantes del modelo de Random Forest.



Cuadro 5. Tabla de métricas del conjunto de entrenamiento para el modelo de XGBoost con PolynomialFeatures.

Etiquetas	Precision	Recall	F1	Support
0	0.95	0.98	0.96	14833
1	0.93	0.87	0.90	5815

Cuadro 6. Tabla de métricas del conjunto de prueba para el modelo de XGBoost con PolynomialFeatures.

Etiquetas	Precision	Recall	F1	Support
0	0.88	0.92	0.90	3709
1	0.76	0.67	0.72	1454

Discusión

En el EDA las variables que mostraban mayor capacidad de predicción fueron: no_of_previous_bookings_not_canceled, no_of_special_requests, no_of_previous_cancellations, repeated_guest y avg_price_per_room.

Las tres principales variables que el modelo XGBoost fueron: required_car_parking_space, no_of_special_requests y type_of_meal_plan_Not_Selected. Las tres principales variables que el modelo Random Forest fueron: lead_time, avg_per_price_room y arrival_time. De éstas solo una coincidió con lo esperado con el EDA, en ambos modelos, esto puede deberse a que las variables no consideradas en un inicio pueden generar una distribución más separada de los datos en otras variables.

Random Forest obtuvo mejores resultados en la predicción del conjunto de prueba, véase cuadro 4, respecto a XGBoost, véase cuadro 2 en el precision de la etiqueta de cancelación, pero menor en el recall. Estos resultados no se considera una diferencia

significativa, sino un distinto balance entre las predicciones, esto se puede observar al comparar las matrices de confusión, véase figura 1 y 3.

Se considera que los dos modelos predijeron de forma regular (70 a 80%) la etiqueta de cancelación de la reserva, esto se puede deber a la naturaleza de los datos, ya que en el EDA solo se observaron 5 variables prometedoras para la separación, mientras que las demás tenían traslapes de etiquetas en toda su distribución.

Ambos modelos presentaron un claro sobreajuste, véase cuadro 1 y 3. Esto debido a que usar validación cruzada y rejillas de hiperparámetros no aseguran el control del sobreajuste, ya que estos procedimientos ayudan a seleccionar una configuración más adecuada del modelo, pero al tener un espacio de hiperparámetro amplio combinado de que los modelo tiene una alta tendencia al sobreajuste, ya que son basados en árboles de decisión, la búsqueda puede encontrar una combinación que se ajusta muy bien a los datos de entrenamiento y validación, pero que no generaliza correctamente a datos no vistos (Hastie y cía. 2019).

En la segunda versión del XGBoost, la que contenía PolynomialFeatures, se observó una mejora no significativa en el rendimiento de predicción del conjunto de prueba, véase cuadro 6, y una ligera mejora en el sobreajuste, véase cuadro 5. Debido a que aún se tiene un sobreajuste alto, se puede evaluar en futuros modelos, el uso de regularización de variables, buscando reducir la cantidad de variables

con el fin de disminuir el sobreajuste de los modelos.

Como ningún modelo demostró tener una capacidad mayor al 80% en la predicción de las cancelaciones de reservas, se puede evaluar en futuros modelos asignar mayor peso a las etiquetas de cancelaciones, aunque se sacrifique la predicción de las no cancelaciones. Esto deberá ser evaluado según las necesidades del cliente y los costos de predecir correcta e incorrectamente cada etiqueta.

Conclusiones

En ambos algoritmos, solo coincidieron con una de las variables esperadas del EDA. Siendo en XGBoost `no_of_special_requests`, y en Random Forest `avg_price_per_room`.

Las tres variables consideradas por XGBoost y Random Forest no coinciden.

Se considera que Random Forest realizó un mejor trabajo en el conjunto de prueba, no significativamente mayor a XGBoost, pero presenta un mayor sobreajuste que este último.

La naturaleza de la mayoría de las variables no muestra capacidad de separación desde el EDA, lo cual puede significar que los modelos tienen una capacidad muy limitada para lograr predicciones adecuadas.

Los modelos de XGBoost y Random Forest presentados pueden considerarse modelos con capacidad regular (70 a 80%)

para clasificar las reservaciones canceladas correctamente.

Se recomienda hacer uso de `PolynomialFeatures` con una selección de variables iterativas, con el fin de mejorar las predicciones de los modelos.

Se recomienda hacer un ajuste de los costos de las etiquetas, con el fin de mejorar la predicción de las cancelaciones de reservas.

Referencias

António, N., Almeida, A. de, & Nunes, L. (2019). Hotel booking demand datasets. *Data in Brief*, 22, 41–49. <https://doi.org/10.1016/j.dib.2018.11.126>

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>

Jann, O. (s. f.). Hotel Booking Cancellations [Data set]. Kaggle. Recuperado el 6 de junio de 2026, de <https://www.kaggle.com/datasets/omegjann/hotel-booking-cancellations/data?select=HotelData.xlsx>