

Proyecto 2








Ricardo Rodríguez 18907

Ian Castellanos 22128



Objetivos

- Determinar las principales variables que permiten predecir la cancelación de una reserva mediante EDA e importancia de características de dos algoritmos de Machine Learning.
- Predecir la cancelación de una reserva mediante dos algoritmos de Machine Learning con el fin de compararlos entre ellos.
- Contrastar los resultados de los dos algoritmos de Machine Learning con lo observado en el EDA, con el fin de determinar las limitaciones de predicción de los datos.



Exploración y limpieza de datos




Exploración y limpieza de datos



Exploración y limpieza de datos



Exploración y limpieza de datos




Métodos usados


- Al trabajar con algoritmos basados en árboles, no se realizó ningún escalado, ya que no son sensibles a escala.
- Para las variables categóricas se utilizó OneHotEncoder.

Resultados XGBoost



	precision	recall	f1-score	support
0.0	0.88	0.91	0.90	3709
1.0	0.75	0.68	0.71	1454
accuracy			0.85	5163
macro avg	0.82	0.80	0.80	5163
weighted avg	0.84	0.85	0.84	5163




Resultados XGBoost



Principales variables del XGBoost



Resultados Random Forest




Etiquetas	Precision	Recall	F1	Support
0	0.88	0.92	0.90	3709
1	0.77	0.66	0.71	1454

Etiquetas:




0: No se canceló la reservación

1: Sí se canceló la reservación

Resultados Random Forest



Principales variables Random Forest



Análisis de sobreajuste de XGBoost

Etiquetas	Precision	Recall	F1	Support
0	0.96	0.98	0.97	14833
1	0.96	0.89	0.92	5815

Métricas de entrenamiento XGBoost

Etiquetas	Precision	Recall	F1	Support
0	0.88	0.91	0.90	3709
1	0.75	0.68	0.71	1454

Métricas de prueba de XGBoost

Análisis de sobreajuste de Random Forest

Etiquetas	Precision	Recall	F1	Support
0	1	1	1	14833
1	0.99	0.99	0.99	5815

Métricas de entrenamiento Random Forest

Etiquetas	Precision	Recall	F1	Support
0	0.88	0.92	0.90	3709
1	0.77	0.66	0.71	1454

Métricas de prueba de Random Forest

Comparación de métricas de ambos métodos


Métricas XGBoost

Etiquetas	Precision	Recall	F1	Support
0	0.88	0.91	0.90	3709
1	0.75	0.68	0.71	1454

Métricas del Random Forest

Etiquetas	Precision	Recall	F1	Support
0	0.88	0.92	0.90	3709
1	0.77	0.66	0.71	1454

Capacidad de separación de variables



Uso de PolynomialFeatures (XGBoost)

Entrenamiento

	precision	recall	f1-score	support
0.0	0.95	0.98	0.96	14833
1.0	0.93	0.87	0.90	5815
accuracy			0.95	20648
macro avg	0.94	0.92	0.93	20648
weighted avg	0.95	0.95	0.95	20648

Prueba

	precision	recall	f1-score	support
0.0	0.88	0.92	0.90	3709
1.0	0.76	0.67	0.72	1454
accuracy			0.85	5163
macro avg	0.82	0.80	0.81	5163
weighted avg	0.85	0.85	0.85	5163

Conclusiones

- En ambos algoritmos, solo coincidieron con una de las variables esperadas del EDA. Siendo en XGBoost `no_of_special_requests`, y en Random Forest `avg_price_per_room`.
- Las tres variables consideradas por XGBoost y Random Forest no coinciden.
- Se considera que Random Forest realizó un mejor trabajo en el conjunto de prueba, no significativamente mayor a XGBoost, pero presenta un mayor sobreajuste que este último.

Conclusiones

- La naturaleza de la mayoría de las variables no muestran capacidad de separación desde el EDA, lo cual puede significar que los modelos tienen una capacidad muy limitada para lograr predicciones adecuadas.
- Los modelos de XGBoost y Random Forest presentados pueden considerarse modelos con capacidad regular para clasificar las reservaciones canceladas correctamente.
- Se recomienda hacer uso de PolynomialFeatures con una selección de variables iterativas, con el fin de mejorar las predicciones de los modelos.